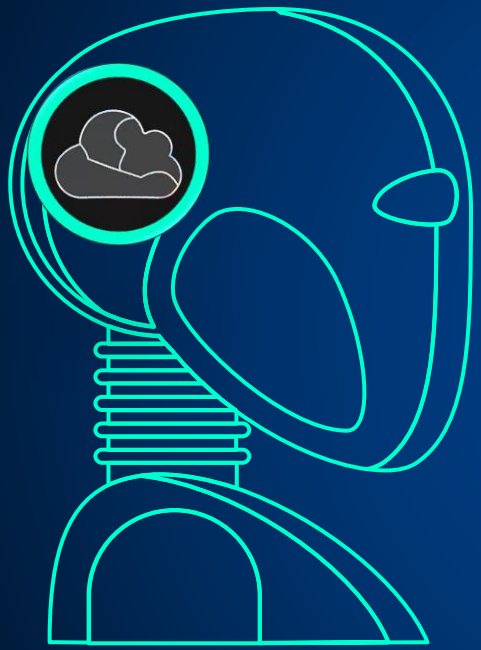

Introdução ao TensorFlow e Keras

Tiago Ajala Mielnik

Semana Integrada da Computação - 2023

ASSUNTOS ABORDADOS

- APRENDIZADO DE MÁQUINA
- REDES NEURAIS E DEEP LEARNING
- PREVISÃO DE SÉRIES TEMPORAIS
- CRIPTOATIVOS
- TENSORFLOW E KERAS
- DESENVOLVIMENTO DE MODELOS DE PREVISÃO DE PREÇOS DE CRIPTOATIVOS

CRONOGRAMA DAS ATIVIDADES

01

INTRODUÇÃO

02

PREPARO DO AMBIENTE

03

PRÉ-PROCESSAMENTO DOS DADOS

04

CONSTRUÇÃO DOS MODELOS

05

TESTES DOS MODELOS

06

CONCLUSÃO

REQUISITOS

- PYTHON BÁSICO
- CONHECIMENTO DE ESTRUTURAS DE DADOS: ARRAYS E MATRIZES

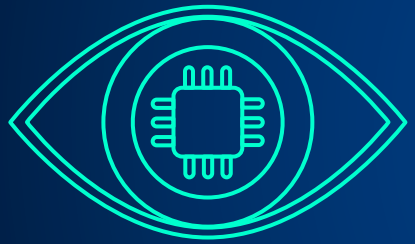

01

INTRODUÇÃO

APRENDIZADO DE MÁQUINA

- SUB-ÁREA DE INTELIGÊNCIA ARTIFICIAL QUE EXPLORA O ESTUDO E DESENVOLVIMENTO DE SISTEMAS COMPUTACIONAIS BASEADOS NO APRENDIZADO DE DADOS;

- PARADIGMA DIFERENTE DA PROGRAMAÇÃO TRADICIONAL: REGRAS/PADRÕES NÃO SÃO PROGRAMADOS, MAS SÃO APRENDIDOS.

TIPOS DE MACHINE LEARNING

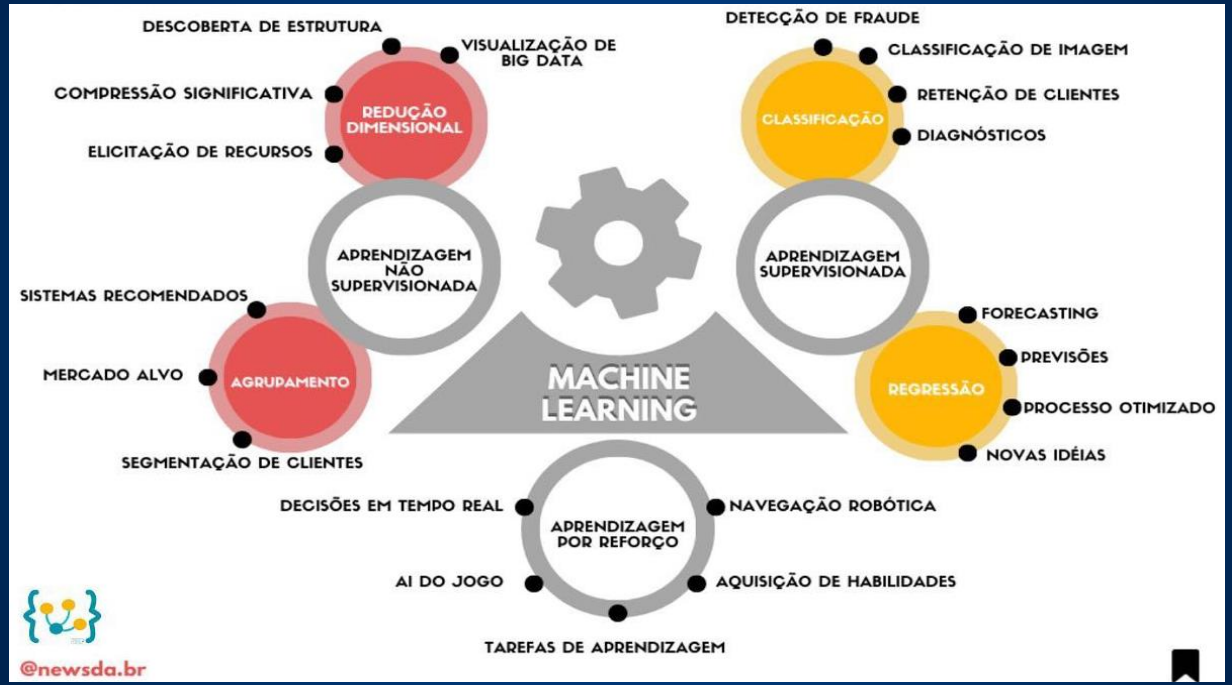

Fonte: Facebook - Núcleo de Estudos em Web Semântica e Análise de Dados / USP

DEEP LEARNING

- SUB-CONJUNTO DE MACHINE LEARNING, CARACTERIZADO PELO APRENDIZADO PROFUNDO E REPRESENTADO PELAS REDES NEURAIS ARTIFICIAIS DE MÚLTIPLAS CAMADAS.

DEEP LEARNING

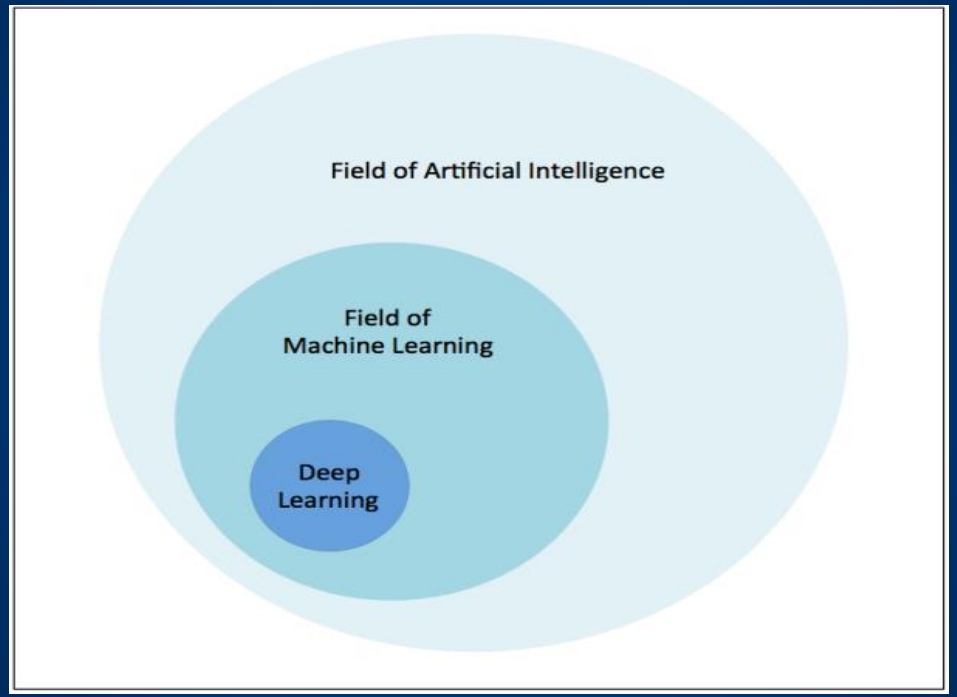

Fonte: J. Patterson and A. Gibson, 2019.

REDES NEURAIS ARTIFICIAIS

- MODELAGEM COMPUTACIONAL PROJETADA PARA SIMULAR O FUNCIONAMENTO DE UM CÉREBRO BIOLÓGICO NA EXECUÇÃO DE TAREFAS;
- POSSUEM CAPACIDADE DE GENERALIZAÇÃO, OU SEJA, CONSEGUEM APRENDER E PRODUZIR RESULTADOS ADEQUADOS PARA ENTRADAS QUE NÃO ESTAVAM PRESENTES DURANTE O SEU TREINAMENTO;
- APRENDIZADO SOBRE GRANDES QUANTIDADES DE DADOS.

NEURÔNIO BIOLÓGICO X ARTIFICIAL

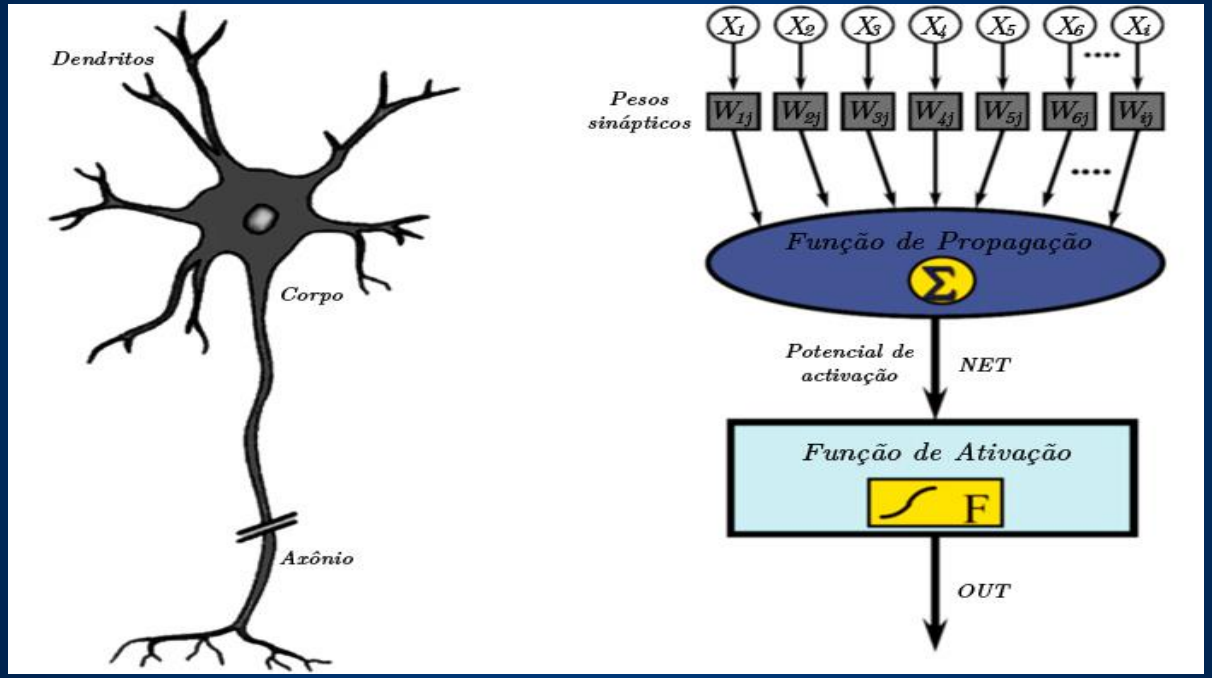

Fonte: (PDF) Inteligência computacional aplicada na geração de respostas impulsivas bi-auriculares e em aurilização de salas (researchgate.net)

REDE NEURAL MULTILAYER PERCEPTRON

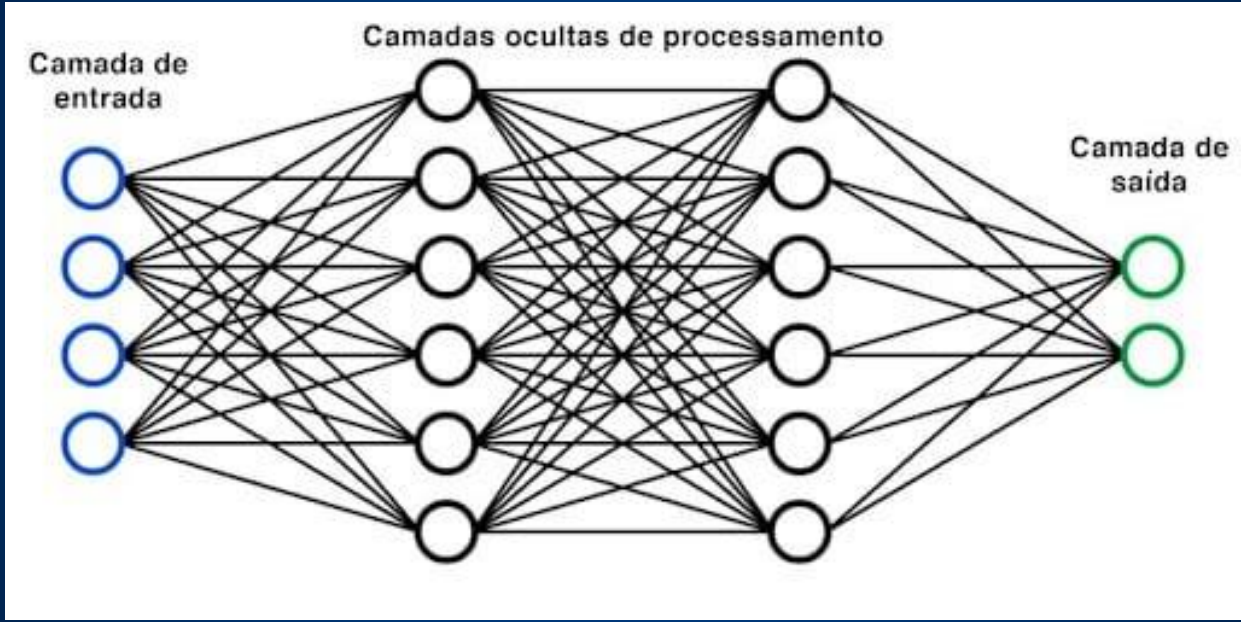

Fonte: O que são Redes Neurais? Importância e Como Funciona? (opencadd.com.br)

APRENDIZADO – REDES NEURAIS

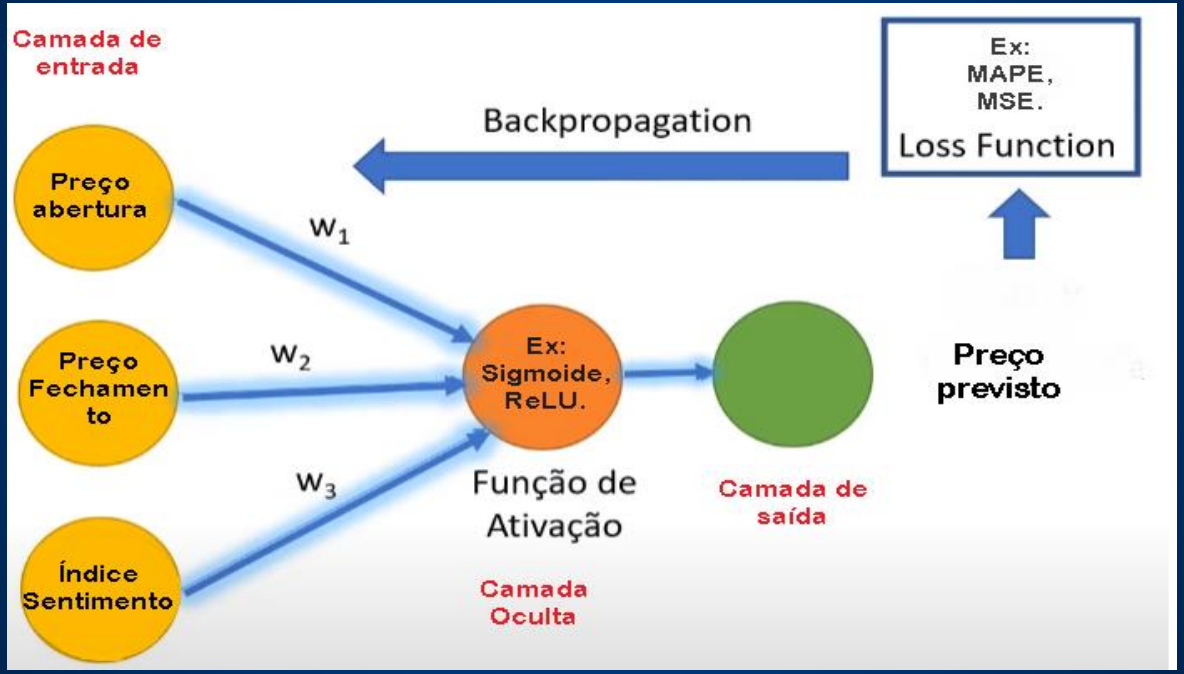

Fonte: Adaptado de https://youtu.be/mWD8wWwZpi8

PREVISÃO DE SÉRIES TEMPORAIS

- SÉRIES TEMPORAIS: CONJUNTO DE OBSERVAÇÕES FEITAS SEQUENCIALMENTE AO DECORRER DE UM PERÍODO DE TEMPO;
- REPRESENTAM DADOS QUE MUDAM AO DECORRER DO TEMPO;
- EXEMPLOS DE PREVISÕES: PREVISÃO DO CLIMA, PREVISÃO DE PREÇOS DE ATIVOS, PREVISÃO DE VENDAS, ETC;
- OBJETIVO: EXTRAIR PADRÕES DE UM CONJUNTO DE DADOS OBSERVADOS EM UM PERÍODO DE TEMPO PASSADO, PARA PREVER COMPORTAMENTOS FUTUROS.

CRIPTOATIVOS

- ATIVOS DIGITAIS QUE UTILIZAM A CRIPTOGRAFIA E A TECNOLOGIA BLOCKCHAIN PARA MANTER SUAS TRANSAÇÕES SEGURAS E INVIOLÁVEIS DE FORMA DESCENTRALIZADA;
- PRINCIPAL CLASSE DE ATIVOS PRESENTES NA WEB 3.0;
- EXEMPLOS: BITCOIN, ETHEREUM, SOLANA, DOGECOIN;

TENSORFLOW

- BIBLIOTECA *OPEN SOURCE* PARA CONSTRUÇÃO DE MODELOS DE *MACHINE LEARNING* PARA COMPUTADORES, *WEB* E DISPOSITIVOS MÓVEIS;
- POSSUI UMA API DE ALTO NÍVEL (KERAS) QUE PERMITE CONSTRUIR MODELOS DE *MACHINE LEARNING* DE FORMA ÁGIL E SIMPLES;
- BIBLIOTECAS SIMILARES: SCIKIT-LEARN, PYTORCH.

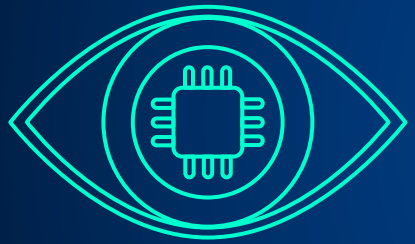

02

PREPARO DO AMBIENTE

BIBLIOTECAS

- tensorflow
- numpy
- yfinance
- pandas
- matplotlib
- ipympl
- scikit-learn

HELLO-WORD DAS REDES NEURAIS

- PRÁTICAR NO JUPYTER-LAB;

- CONSTRUIR UM MODELO QUE ENCONTRE O PADRÃO NOS DADOS ROTULADOS ABAIXO E FAÇA AS PREVISÕES PARA NOVOS DADOS DE ENTRADA:

X = [-1.0, 0.0, 1.0, 2.0, 3.0, 4.0]
Y = [-3.0, -1.0, 1.0, 3.0, 5.0, 7.0]

X: REPRESENTA OS DADOS DE ENTRADA DO MODELO .
Y: REPRESENTA OS VALORES DE SAÍDA DO MODELO.

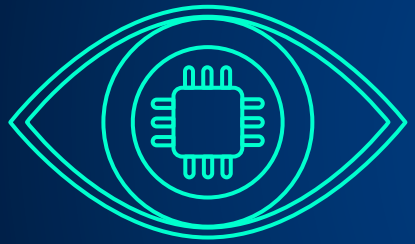

03

PRÉ-PROCESSAMENTO DOS DADOS

REDIMENSIONAMENTO DOS DADOS

- OS MODELOS PRECISAM QUE OS DADOS ESTEJAM ESTRUTURADOS NO FORMATO DE ARRAYS/MATRIZES;
- SHAPE: FORMATO (DIMENSÃO) DOS DADOS EM ARRAYS/MATRIZES;
- RESHAPE: TÉCNICA PARA REDIMENSIONAR OS DADOS EM ARRAYS/MATRIZES;
- AO CONSTRUIR OS MODELOS, NA CAMADA DE ENTRADA É PRECISO ESPECIFICAR O SHAPE DA MATRIZ DOS DADOS DE ENTRADA E FORNCÊ-LOS NO FORMATO ESPERADO PELA REDE NEURAL.

SHAPE EM ARRAYS

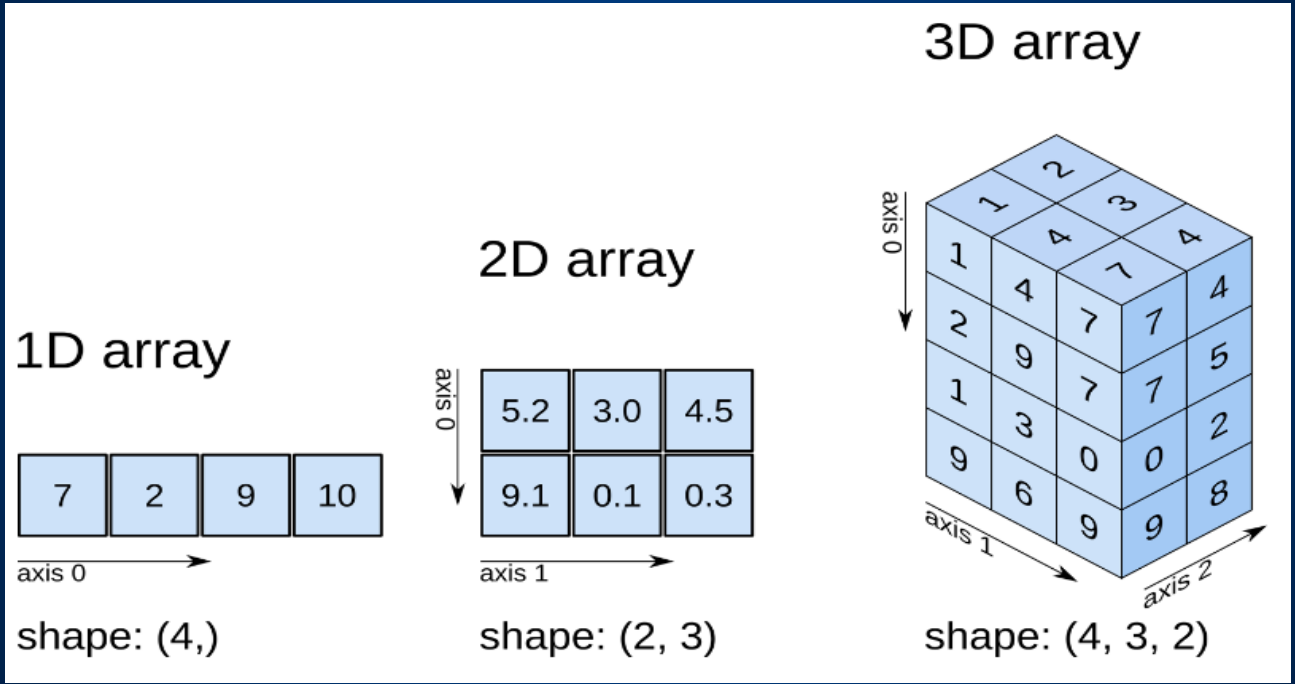

Fonte: python - Numpy's "shape" function returns a 1D value for a 2D array - Stack Overflow

COLETA DE DADOS

- UTILIZAR A BIBLIOTECA YFINANCE PARA COLETAR OS DADOS DE PREÇOS DO CRIPTOATIVO BITCOIN;
- OS DADOS DA BIBLIOTECA YFINANCE SÃO RETORNADOS NO FORMATO DE UM DATAFRAME DE DUAS DIMENSÕES;
- UTILIZAR MÉTODOS .INFO, .HEAD, .TAIL PARA VISUALIZAR AS INFORMAÇÕES DO DATAFRAME E AMOSTRAS DOS DAADOS.

DIVISÃO DOS DADOS

- DIVIDIR OS DADOS EM DOIS CONJUNTOS, UM PARA TREINO (90%) E OUTRO PARA TESTES (10%). UTILIZAR O MÉTODO TRAIN_TEST_SPLIT DA BIBLIOTECA SCIKIT-LEARN;

- O OBJETIVO É TREINAR O MODELO COM UM CONJUNTO DE DADOS, E TESTÁ-LO COM OUTROS DADOS QUE ELE NÃO TEVE ACESSO NO TREINAMENTO;

NORMALIZAÇÃO DOS DADOS

- TRANSFORMA AS DIFERENTES ESCALAS DE VALORES DAS *FEATURES* EM UM INTERVALO ESPECÍFICO DEFINIDO ENTRE 0 E 1 OU ENTRE -1 E 1. UTILIZAR A CLASSE MINMAXSCALER DA BIBLIOTECA SCIKIT-LEARN;

- BOA PRÁTICA PARA REALIZAR O TREINAMENTO DE REDES NEURAIS, POIS ESTAS TRABALHAM INTERNAMENTE COM PEQUENOS VALORES EM SEUS PARÂMETROS;

- APÓS O TREINAMENTO, É PRECISO FAZER A DESNORMALIZAÇÃO DOS DADOS E VOLTÁ-LOS PARA A ESCALA ORIGINAL DE VALORES.

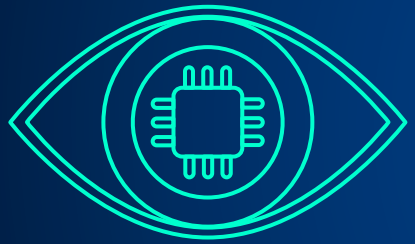

04

CONSTRUÇÃO DOS MODELOS

CONSTRUÇÃO: MODELO ANN (MLP)

- UTILIZAR API KERAS DO TENSORFLOW;
- UTILIZAR UMA CAMADA DENSA COM 64 NEURÔNIOS;
- FUNÇÃO DE ATIVAÇÃO: TANGENTE HIPERBÓLICA (TANH);
- INPUT_SHAPE: MATRIZ DE DADOS COM 5 FEATURES (OPEN, HIGH, LOW, VOLUME, CLOSE);
- UTILIZAR UMA CAMADA DE SAÍDA DO TIPO DENSA COM 1 NEURÔNIO (SAÍDA É A PREVISÃO PARA O PRÓXIMO DIA);
- UTILIZAR O ALGORITMO OTIMIZADOR ADAM;
- COMPILAR O MODELO COM A FUNÇÃO DE PERDA MAE (MEAN ABSOLUTE ERROR)

CONSTRUÇÃO: MODELO ANN (MLP)

```
model = keras.Sequential(name='ANN_ONE-STEP-FORECAST')
model.add(layers.Dense(units=64, activation='tanh', input_shape=(x_train.shape[1],))) # Funções de ativação: sigmoid, tanh, relu,
model.add(layers.Dense(1))

# Define o algoritmo otimizador dos pesos da rede neural e a taxa de aprendizado
opt = keras.optimizers.Adam() # learning_rate=0.001 por padrão

# Compila o modelo definindo a função de perda para cálculo do erro e o algoritmo otimizador.
model.compile(loss='mae', optimizer=opt) # Funções de perda para testar: mae, mse, msle, huber, log_cosh
```

Fonte: Elaboração própria.

TREINAMENTO: MODELO ANN (MLP)

- TREINAR O MODELO POR MEIO DO MÉTODO FIT;
- INFORMAR OS DADOS ROTULADOS (TREINAMENTO E TESTES);
- TREINAR POR 100 ÉPOCAS;
- DEFINIR O BATCH_SIZE COM UM VALOR DE 32;
- DEFINIR O PARÂMETRO SHUFFLE = TRUE

TREINAMENTO: MODELO ANN (MLP)

```
%%time

# Treina o modelo
history = model.fit(x_train, y_train, epochs=100, batch_size=32, verbose=1, shuffle=True, validation_data=(x_test, y_test))
```

Fonte: Elaboração própria.

- AVALIAR O ERRO DO TREINAMENTO COM A BIBLIOTECA MATPLOTLIB.

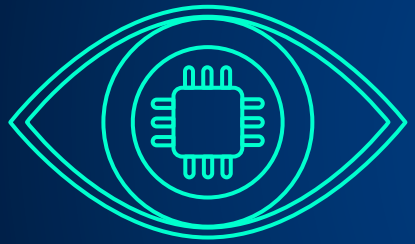

05

TESTES DOS MODELOS

TESTES: MODELO ANN (MLP)

- OS TESTES DE PREVISÃO SÃO FEITOS A PARTIR DOS DADOS DE TESTES QUE NÃO FORAM CONHECIDOS PELO MODELO DURANTE O TREINAMENTO;
- FAZER PREVISÃO POR MEIO DO MÉTODO “PREDICT”, FORNECENDO OS DADOS DE ENTRADA DO CONJUNTO DE TESTES;
- DESNORMALIZAR OS VALORES PREVISTOS E TRANSFORMÁ-LOS PARA A ESCALA ORIGINAL;
- DESNORMALIZAR OS VALORES REAIS E TRANSFORMÁ-LOS PARA A ESCALA ORIGINAL E COMPARAR COM OS VALORES PREVISTOS.

TESTES: MODELO ANN (MLP)

```python
# Função que transforma os dados normalizados pelo scaler para a escala orignal
def transform_orignal_scale(array_data):
    scaler_min_value = scaler.feature_range[0] # Obtém o menor valor do scaler
    scaler_max_value = scaler.feature_range[1] # Obtém o maior valor do scaler
    original_data_min = data_train[['Close']].values.min(axis=0)
    original_data_max = data_train[['Close']].values.max(axis=0)

    return (array_data - scaler_min_value) / (scaler_max_value - scaler_min_value) * (original_data_max - original_data_min) + original_data_min
```

Fonte: Elaboração própria.

TESTES: MODELO ANN (MLP)

```
# Teste de predição a partir dos dados de testes
predictions = model.predict(x_test)

# Desnormalização dos dados de predição (transforma para a escala original)
predictions = transform_orignal_scale(predictions)
print(predictions.shape)
print(predictions[-1:])
```

```
# Desnormalização dos valores reais (transforma para a escala original)
real_prices = transform_orignal_scale(y_test)
print(real_prices.shape)
print(real_prices[-1:])
```

Fonte: Elaboração própria.

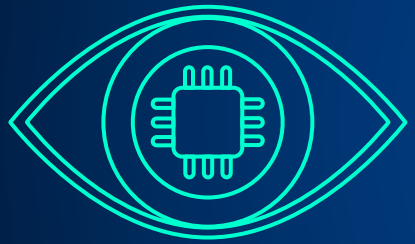

06

CONCLUSÃO

VISUALIZAÇÃO DOS RESULTADOS

- COMPARAR OS VALORES PREVISTOS COM OS VALORES REAIS A PARTIR DO CONJUNTO DE DADOS DE TESTES;
- UTILIZAR A BIBLIOTECA MATPLOTLIB PARA CRIAR O GRÁFICO;
- UTILIZAR A MÉTRICA MAPE (MEAN ABSOLUTE PERCENTAGE ERROR) PARA MEDIR O ERRO DO MODELO;

VISUALIZAÇÃO DOS RESULTADOS

```python
# Plota o gráfico comparativo entre os valores reais x previstos
epochs = range(len(y_test))
plt.figure(figsize=(13, 5))
plt.plot(epochs, real_prices, label='Real')
plt.plot(epochs, predictions, label='Previsto')
plt.title(f'Preço real x previsto: {SYMBOL}')
plt.xlabel('Epochs')
plt.ylabel('Loss')
#plt.semilogy()
plt.legend()
plt.grid()

plt.show()
```

Fonte: Elaboração própria.

VISUALIZAÇÃO DOS RESULTADOS

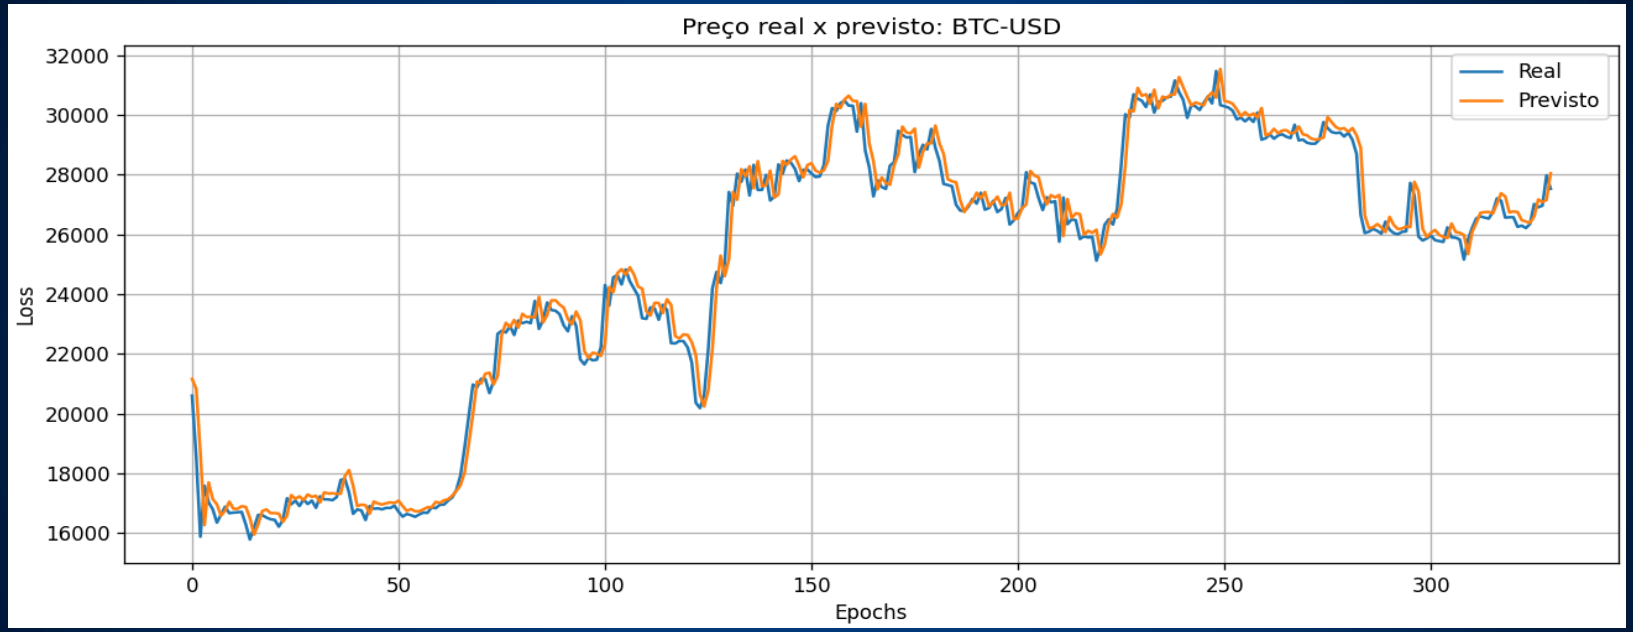

Fonte: Elaboração própria.

AVALIAÇÃO DOS RESULTADOS: MAPE

```
# Avaliação da métrica MAPE
mape = tf.keras.metrics.MeanAbsolutePercentageError()
mape.update_state(real_prices, predictions)
mape_result = mape.result().numpy()

print(f'MAPE: {mape_result}')
```

```
MAPE: 1.7494179010391235
```

Fonte: Elaboração própria.

- REPRESENTA O ERRO MÉDIO ABSOLUTO EM PERCENTUAL DE TODAS AS PREVISÕES FEITAS A PARTIR DO CONJUNTO DE TESTES.

É POSSÍVEL MELHORAR?

- UTILIZAR ARQUITETURAS DE REDES NEURAIS MAIS ROBUSTAS PARA PROBLEMAS DE SÉRIES TEMPORAIS: RNN, LSTM E ARQUITETURAS HÍBRIDAS;
- TESTAR DIFERENTES PARÂMETROS DO MODELO: NUMERO DE NEURÔNIOS, QUANTIDADE DE CAMADAS OCULTAS, FUNÇÕES DE PERDA, ALGORITMOS OTIMIZADORES, REGULARIZADORES, BATCH_SIZE, ÉPOCAS, ETC;
- ENGENHARIA DE DADOS PARA MELHORAR A SELEÇÃO DE FEATURES E O PRÉ-PROCESSAMENTO DOS DADOS.

REFERÊNCIAS

- M. Swamynathan. Mastering Machine Learning with Python in Six Steps: A Practical Implementation Guide to Predictive Data Analytics Using Python. Apress, 2019.
- J. Patterson and A. Gibson. *Deep Learning: A Practitioner's Approach*. O'Reilly Media, 2017.
- C. Burniske and J. Tatar. *Cryptoassets: The Innovative Investor's Guide to Bitcoin and Beyond*. McGraw-Hill Education, 2017.
- Previsão de séries temporais | TensorFlow Core
- Time Series Forecasting as Supervised Learning - MachineLearningMastery.com
- scikit-learn: machine learning in Python — scikit-learn 1.3.1 documentation
- Keras: Deep Learning for humans
- yfinance · PyPI
- NumPy
- pandas - Python Data Analysis Library (pydata.org)
- Matplotlib — Visualization with Python